

实验 2. 隐马尔科夫模型实践

MF1733034, 李青坪, lqp19940918@163.com

2017 年 11 月 29 日

综述

本次试验将实现隐马尔科夫模型 [1] (Hidden Markov Model, HMM), 并将其应用在金融时序数据分析与预测方面。具体而言, 对于一个已经训练好的 HMM, 实现一个维特比算法, 通过动态规划的思想对模型进行推断, 其次, 如果 HMM 的参数未知, 则需要通过数据进行学习与训练, 这里将部分实现 Baum-Welch_algorithm. 你将负责其中两个关键函数: HMM 的前向与后向算法。最后, 利用自己从零开始写好的 HMM, 进行股票的涨跌预测 (for fun), 我们将预测中国某支与 AI 相关的股票的走势。

对于单只股票数据, 我们每日可以观测到的值可以是涨、跌, 不涨不跌 (相对于昨天的收盘价) 三种情况。这里将观测的涨跌平编码为 0,1,2 三种取值 (0: 跌, 1: 涨, 2: 平)。我们假设股票的涨跌由内在的隐变量驱动 (这是一个十分简化的假设), 即牛市或熊市。换言之, 牛市 (编码为 1) 比较有可能驱动股票价格上涨, 熊市 (编码为 0) 比较有可能驱动股票下跌。换言之, 在本 HMM 模型中, 隐变量仅仅是 1 维的 0/1 离散状态。

实验一.

维特比算法的概念

维特比算法是一种动态规划算法, 它用于寻找最有可能产生观测事件序列的维特比路径——隐含状态序列, 特别是在马尔可夫信息源上下文和隐马尔可夫模型中。维特比算法是针对一个特殊的图——篱笆网络的有向图而提出的, 可以从图中找到最短路径, 包括数字通信、语音识别、机器翻译等用到隐马尔可夫模型的技术都可以用维特比算法来解码。

维特比算法的实现

给定隐马尔可夫模型的参数 $\lambda = [\mathbf{A}, \mathbf{B}, \boldsymbol{\pi}]$, \mathbf{A} 表示状态转移概率矩阵, a_{ij} 表示状态 i 转换到状态 j 的概率; \mathbf{B} 表示输出观测概率矩阵, b_{ij} 表示根据状态 i 获得观测值 o_j 的概率; $\boldsymbol{\pi}$ 表示初始状态概率, \mathbf{X} 表示观测序列 $\{x_1, x_2, \dots, x_T\}$, S 表示具有 N 个状态的状态空间。

最有可能产生的状态序列 $Y = \{y_1, y_2, \dots, y_T\}$ 由以下递推关系给出:

$$\begin{aligned} V_{1,k} &= p(x_1|k) * \pi_k \\ V_{t,k} &= p(x_t|k) * \max_{y \in S} (a_{y,k} * V_{t-1,y}) \end{aligned}$$

设 path 记录从每一个状态开始，最有可能到达的路径。对于某一状态 y 找到使 $V_{t,y}$ 最大的上一个状态 state，则将 $[y]$ 加入 $\text{path}[\text{state}]$ 中，直到走完一整条观测序列，找到 T 时刻最大概率所对应的状态 s ，则 $\text{path}[s]$ 即为最有可能的状态路径。

实验二.

Forward 算法的实现

使 $\alpha_i(t) = p(X_1 = x_1, X_2 = x_2, \dots, X_t = x_t, Y_t = i | \lambda)$ 表示在 t 时刻，处于状态 i ，且观测到 $\{x_1, x_2, \dots, x_t\}$ 序列的概率。 $\alpha_i(t)$ 的值由以下式子递归得出：

$$\begin{aligned}\alpha_i(1) &= \pi_i b_i(x_1) \\ \alpha_i(t+1) &= b_i(x_{t+1}) \sum_{j=1}^N \alpha_j(t) a_{ji}.\end{aligned}$$

Forward 算法与维特比算法区别在于：前者是求出在 $t-1$ 时刻，状态空间里面所有的状态能够在 t 时刻转移到状态 i 的概率之和作为 $\alpha_i(t)$ ；后者是求出在 $t-1$ 时刻，状态空间中的某一状态 y ， y 能够在 t 时刻转移到状态 i 的概率最大， $V_{t,y}$ 则为该最大概率。前者用于训练 HMM 模型，后者是用于利用训练后的 HMM 模型根据观测序列计算最有可能出现的状态序列。

实验三.

使 $\beta_i(t) = p(X_{t+1} = x_{t+1}, X_{t+2} = x_{t+2}, \dots, X_T = x_T | Y_t = i, \lambda)$ 在时刻 t ，给定开始状态 i ，观测到结尾部分序列的 $\{x_{t+1}, x_{t+2}, \dots, x_T\}$ 的概率。可通过以下式子计算 $\beta_i(t)$ ：

$$\begin{aligned}\beta_i(T) &= 1 \\ \beta_i(t) &= \sum_{j=1}^N \beta_j(t+1) a_{ij} b_j(x_{t+1}).\end{aligned}$$

$\beta_i(t)$ 表示的意思就是，在 $t+1$ 时刻，状态空间中的所有状态能够在 t 时刻从状态 i 转移过来的概率之和。

实验结果

实验中，通过 Baum-Welch 算法训练出 HMM 模型，并利用维特比算法进行推断，预测股价的涨跌。执行 HMM_test.py 脚本，验证代号为 002415 的股票在今年的预测准确度，实验结果表明，准确度在 64.7% 左右。如图 1 所示：

```
konnase@ubuntu17:~/workspace/homework/machine_learning/hidden_markov_model/assign2_code_v2$ python HMM_test.py
start
0.647058823529
```

图 1: 实验结果

参考文献

- [1] 周志华. 机器学习: = *Machine learning*. 清华大学出版社, 2016.